

COMITÊ DE CLASSIFICADORES

Predição de Doenças Cardíacas via Ensemble Learning e Machine Learning

Autores: Aniel Paulo, Isabela Lima, João Pedro, Matheus Caires

Instituição: Universidade São Judas Tadeu (2026)

O Desafio Cardiológico

As doenças cardiovasculares são um dos maiores desafios da medicina global. Identificar precocemente o risco salva vidas e otimiza intervenções.

Com o avanço da **Ciência de Dados**, informações clínicas estruturadas podem alimentar modelos preditivos precisos.

O objetivo deste projeto é aplicar técnicas de Inteligência Artificial para analisar um conjunto de dados clínicos e classificar a presença de doenças cardíacas usando uma estratégia robusta de *Ensemble Learning*.



Descrição da Base de Dados

O *dataset* é composto por **271 registros de pacientes**, estruturados através de diversas variáveis clínicas e exames.



Dados Demográficos

Informações básicas sobre o perfil do paciente, incluindo a **idade (age)** em anos e o **sexo (sex)** biológico para estratificação inicial de risco.



Condições Clínicas

Medições vitais como **tipo de dor no peito (cp)**, **pressão arterial (trestbps)**, **colesterol sérico (chol)** e níveis de açúcar em jejum (**fbs**).



Resultados de Exames

Variáveis complexas incluindo **resultados eletrocardiográficos (restecg)**, **frequência máxima (thalach)**, e depressão/inclinação do segmento ST.

Definição do Problema (Target)

O projeto caracteriza-se como um problema de **aprendizado supervisionado de classificação binária**. O modelo deve prever uma resposta objetiva (o "gabarito") a partir do quadro clínico.

Estado 0: Ausência de Doença

Indica que, com base nos exames e dados fornecidos, o paciente **não apresenta** evidências clínicas de comprometimento ou doença cardíaca.

Representa a classe de pacientes considerados saudáveis no escopo cardiovascular estudado.

Estado 1: Presença de Doença

Indica a identificação de padrões clínicos que apontam para a **existência** de uma doença cardíaca.

Destaca os casos prioritários que necessitam de intervenção ou acompanhamento médico especializado.

Pré-processamento dos Dados

2. Divisão (Split)

Separação em **Treino (80%)** para
aprendizado dos padrões e **Teste**

Dados clínicos brutos possuem variações de escala que comprometem o treinamento matemático. A preparação seguiu três etapas rigorosas:

(20%) para validação cega, evitando a memorização (overfitting).

1. Limpeza

Remoção de registros incompletos e nulos (*dropna*) para assegurar que os algoritmos treinem apenas com observações completas e íntegras.

3. Padronização

Uso do *StandardScaler* para transformar todas as variáveis numéricas (média zero, desvio padrão unitário), neutralizando o viés das escalas maiores.


Algoritmos Base Seleccionados

Três modelos com paradigmas de aprendizado distintos foram selecionados para diversificar a lógica preditiva:



KNN

Baseado em instâncias. Classifica os pacientes de acordo com a similaridade "espacial" aos seus vizinhos mais próximos ($k=5$).



Árvore de Decisão

Cria um fluxo de decisões hierárquico baseado em regras de corte lógicas. Destaca-se por sua alta interpretabilidade médica.



SVM

Support Vector Machine. Busca maximizar a margem (hiperplano) de separação matemática entre pacientes saudáveis e doentes.

Construção do Comitê (Ensemble)

O coração do projeto é a integração dos classificadores num único modelo de comitê, utilizando o **Soft Voting** via *VotingClassifier*.

- **Mecanismo Probabilístico:** O sistema não vota na decisão final ("0" ou "1"), mas soma as *probabilidades* que cada modelo atribui a cada classe.
- **Mitigação de Viés:** Cada algoritmo possui um "ponto cego" (KNN foca na densidade, SVM na margem). O comitê anula fraquezas isoladas.
- **Robustez:** O modelo mais confiante "salva" o modelo incerto. O resultado é um diagnóstico colegiado mais resiliente e estável.



Comparativo de Desempenho (Acurácia)

Resultados obtidos sobre os dados de teste invisíveis (20% do dataset), comprovando a capacidade de generalização:



O Comitê estabilizou a predição. Apesar do SVM individual ter um ligeiro pico de acerto neste corte de dados, o Ensemble assegura que o sistema não dependa da fragilidade de um único modelo.

Análise da Matriz de Confusão (Comitê)

A validação final ocorreu sobre 54 pacientes de teste, mapeando a natureza estatística dos acertos e erros do Ensemble:

Predição do Modelo	Realidade: Saudável (0)	Realidade: Doente (1)
Previu Saudável (0)	Verdadeiros Negativos (VN) 29	Falsos Negativos (FN) 4
Previu Doente (1)	Falsos Positivos (FP) 4	Verdadeiros Positivos (VP) 17

A Crítica aos Falsos Negativos

4

Falsos Negativos

O Custo do Erro Médico

Na ciência de dados aplicada à saúde, nem todo erro tem o mesmo peso. **Um falso negativo implica que um paciente doente foi classificado como saudável e pode não receber tratamento a tempo.**

Com apenas 4 ocorrências em 54 pacientes, o modelo de Comitê demonstra capacidade de triagem muito eficaz.

Este índice justifica o uso da ferramenta como suporte, preservando a necessidade inerente da avaliação humana final.

Discussão e Implicações



Tamanho da Base

O modelo obteve sucesso, mas usou apenas ~300 registros. A transição para um ambiente clínico real de larga escala exigiria um *dataset* significativamente mais denso.



Viés Oculto

Os dados limitam o aprendizado. Fatores externos vitais (ex: genética, classe socioeconômica, histórico familiar) não foram computados neste conjunto inicial.



Apoio Clínico

O conceito central provado é a **Inteligência Aumentada**. O sistema não substitui o médico; ele organiza a triagem e otimiza a fila de atendimento hospitalar.

Conclusão

O Comitê de Classificadores atingiu 85,19% de acurácia com a técnica Soft Voting, mitigando pontos cegos individuais.
Demonstramos que a combinação matemática e o rigor pré-processamento são a chave para sistemas de triagem cardíaca viáveis.

Dúvidas?

Projeto A3 - Universidade São Judas Tadeu (2026)
Aniel Paulo • Isabela Lima • João Pedro • Matheus Caires