



UNIVERSIDADE SÃO JUDAS TADEU
RELATÓRIO – PROJETO A3 – 1º SEM/2026

COMITÊ DE CLASSIFICADORES

ANIEL PAULO NINA PURGA - 825157942

ISABELA LIMA ALENCAR - 825110676

JOÃO PEDRO DE OLIVEIRA SALAZAR - 825133002

MATHEUS CAIRES - 825127880

SÃO PAULO

2026

SUMÁRIO

1 INTRODUÇÃO	3
2 DESCRIÇÃO DA BASE DE DADOS	4
3 DEFINIÇÃO DO PROBLEMA (TARGET)	5
4 PRÉ-PROCESSAMENTO DOS DADOS	6
5 MODELAGEM.....	7
5.1 Algoritmos selecionados	7
5.2 Metodologia de Avaliação	7
6 CONSTRUÇÃO DO COMITÊ	8
6.1 Estratégia de Votação (Soft Voting)	8
6.2 Justificativa da Robustez	8
7 RESULTADOS E MÉTRICAS.....	9
7.1 Comparativo de Desempenho	9
7.2 Análise da Matriz de Confusão (Modelo de Comitê)	9
7.3 Conclusão sobre as Métricas.....	10
8 DISCUSSÃO	11
8.1 Análise da Robustez dos Modelos	11
8.2 Limitações do Estudo	11
8.3 Implicações Clínicas	11
9 CONCLUSÃO.....	13

1. INTRODUÇÃO

As doenças cardiovasculares continuam sendo um dos maiores desafios globais para a medicina e são responsáveis por um grande impacto na qualidade de vida da população. Diante desse cenário, a capacidade de identificar precocemente o risco de algumas complicações cardíacas não é apenas uma questão técnica, mas uma necessidade real que pode salvar vidas e permitir intervenções médicas mais rápidas. Com o avanço da tecnologia nos últimos anos, a Ciência de Dados surgiu como uma aliada muito poderosa, permitindo que informações clínicas possam ser utilizadas para prever diagnósticos de forma mais precisa.

O objetivo deste projeto é aplicar técnicas de Inteligência Artificial para analisar um conjunto de dados clínicos e verificar a possibilidade de identificar a presença ou ausência de doenças cardíacas em pacientes. Iniciamos o projeto organizando e limpando os dados (pré-processamento), para garantir que as informações estivessem prontas para a análise, e avançamos para o treinamento de modelos de aprendizado de máquina.

Optamos por utilizar três abordagens distintas — o K-Nearest Neighbors (KNN), a Árvore de Decisão e a Support Vector Machine (SVM). Além disso, a estratégia central deste projeto foi a criação de um modelo de comitê (Ensemble Learning), uma técnica que combina o conhecimento de diferentes algoritmos para gerar uma conclusão final mais sólida e menos sujeita a erros isolados.

2. DESCRIÇÃO DA BASE DE DADOS

Para a realização desse trabalho, foi utilizado um conjunto de dados referente a diagnósticos de doenças cardíacas. A base de dados é composta por informações clínicas de pacientes, sendo estruturada em variáveis numéricas que descrevem condições de saúde e exames realizados.

O dataset apresenta um total de 271 linhas, cada uma representando um paciente e é composto pelos seguintes atributos (variáveis independentes):

- **Idade (age):** Idade do paciente em anos.
- **Sexo (sex):** Identificação do gênero do paciente.
- **Tipo de dor no peito (cp):** Classificação do tipo de dor torácica apresentada.
- **Pressão arterial em repouso (trestbps):** Medida da pressão arterial do paciente.
- **Colesterol sérico (chol):** Nível de colesterol no sangue, medido em mg/dl.
- **Açúcar no sangue em jejum (fbs):** Indicador se o nível de glicose em jejum é superior a 120 mg/dl.
- **Resultados eletrocardiográficos (restecg):** Resultados obtidos no eletrocardiograma.
- **Frequência cardíaca máxima (thalach):** A maior frequência cardíaca atingida pelo paciente durante testes.
- **Angina induzida por exercício (exang):** Indica se o paciente desenvolveu dor torácica durante o esforço físico.
- **Depressão do segmento ST (oldpeak):** Medida da alteração no traçado do eletrocardiograma.
- **Inclinação do segmento ST (slope):** Inclinação do pico do exercício no eletrocardiograma.
- **Número de vasos principais (ca):** Quantidade de vasos sanguíneos identificados em exames de imagem.
- **Estado da talassemia (thal):** Condição hematológica avaliada.

3. DEFINIÇÃO DO PROBLEMA (TARGET)

O objetivo central deste trabalho é a classificação automática da presença ou ausência de doenças cardíacas em pacientes, baseada em um conjunto de variáveis clínicas. O problema caracteriza-se como um desafio de aprendizado supervisionado de classificação binária, onde o modelo deve aprender padrões presentes nas características de saúde do paciente para prever um diagnóstico.

A variável alvo, denominada **target**, foi definida como o pilar de todo o processo de modelagem. Ela atua como o "gabarito" do sistema, sendo composta por dois estados possíveis:

- **0 (Ausência de doença):** Indica que, com base nos dados fornecidos, o paciente não apresenta evidências clínicas de comprometimento cardíaco.
- **1 (Presença de doença):** Indica a identificação de padrões clínicos que apontam para a existência de uma doença cardíaca.

A escolha dessa variável como “target” é fundamental porque transforma uma questão médica e a interpretação de diversos exames médicos em uma resposta objetiva. Ao treinar os modelos para prever este *target*, o sistema torna-se capaz de auxiliar na triagem de pacientes, destacando casos que necessitam de atenção médica prioritária. Portanto, a precisão na predição deste diagnóstico é o principal indicador de sucesso e utilidade clínica de todo o sistema desenvolvido neste relatório.

4. PRÉ-PROCESSAMENTO DOS DADOS

O pré-processamento dos dados é uma das etapas mais críticas de qualquer projeto de Ciência de Dados. Dados brutos, como os obtidos em ambientes clínicos, frequentemente apresentam variações de escala e inconsistências que podem comprometer o aprendizado dos modelos. Portanto, o objetivo desta fase foi garantir que a base de dados estivesse padronizada e apta para o treinamento dos algoritmos.

As etapas de pré-processamento foram conduzidas da seguinte maneira:

1. Limpeza e Tratamento: Inicialmente, foi realizada uma inspeção para identificar inconsistências no conjunto de dados. Registros incompletos ou valores nulos foram tratados para garantir que apenas observações completas fossem utilizadas.

2. Divisão dos Dados (Split): Para garantir uma avaliação imparcial, o conjunto de dados foi dividido em dois subconjuntos distintos:

- **Dados de Treino (80%):** Utilizados para permitir que os modelos aprendessem os padrões associados ao diagnóstico cardíaco.
- **Dados de Teste (20%):** Reservados exclusivamente para a validação final, funcionando como um "simulado" onde o modelo precisa prever diagnósticos de pacientes que nunca "viu" anteriormente.

3. Normalização (Padronização): Esta etapa foi essencial, visto que modelos como o *K-Nearest Neighbors* (KNN) e o *Support Vector Machine* (SVM) operam com base no cálculo de distâncias entre os dados. Como as variáveis do estudo possuem unidades de medida distintas (por exemplo, pressão arterial em mmHg versus colesterol em mg/dl), foi aplicada a técnica de padronização via *StandardScaler*. Este procedimento transformou os dados para que todos possuísem média zero e desvio padrão unitário, evitando que variáveis com valores numéricos naturalmente maiores dominassem o processo de aprendizagem em detrimento de variáveis menores.

Este tratamento garantiu que os algoritmos operassem em condições de igualdade, focando na relevância clínica de cada parâmetro do paciente, e não na sua escala numérica. Com os dados normalizados e divididos, o ambiente tornou-se tecnicamente preparado para o início da fase de modelagem.

5. MODELAGEM

A fase de modelagem representa o núcleo deste projeto, onde foram aplicadas técnicas de aprendizagem supervisionada para a classificação de doenças cardíacas. O objetivo desta etapa foi treinar modelos capazes de identificar padrões ocultos no conjunto de dados, permitindo a predição da variável alvo com a maior precisão possível.

5.1. Algoritmos Selecionados

Para esta investigação, optou-se pela implementação de três algoritmos com paradigmas de aprendizado distintos. A diversidade nas abordagens escolhidas permite que o sistema final não dependa de uma única lógica matemática, aumentando a robustez da solução:

- **K-Nearest Neighbors (KNN):** Este algoritmo foi escolhido por ser baseado em instâncias. Ele classifica novos dados com base na similaridade com os vizinhos mais próximos no espaço de atributos. É uma técnica eficaz para problemas onde a proximidade entre os dados clínicos é um indicador forte de similaridade diagnóstica.
- **Árvore de Decisão:** Este modelo cria um fluxo de decisões baseado em regras lógicas, organizadas de forma hierárquica. Sua principal vantagem é a interpretabilidade, permitindo compreender quais variáveis (como a pressão arterial ou a idade) possuem maior peso na decisão final do diagnóstico.
- **Support Vector Machine (SVM):** O SVM foi utilizado por sua eficácia em problemas de classificação binária. O algoritmo busca definir a fronteira (hiperplano) que melhor separa as classes de pacientes (doentes vs. saudáveis), focando em maximizar a margem de separação entre elas, o que geralmente resulta em modelos com alta capacidade de generalização.

5.2. Metodologia de Avaliação

Para garantir a confiabilidade dos resultados, cada algoritmo foi submetido a um processo de avaliação individual. A métrica principal utilizada foi a acurácia, que indica o percentual de acertos do modelo sobre o conjunto de dados de teste.

Além disso, foi gerada a Matriz de Confusão para cada modelo. Esta ferramenta foi essencial para identificar não apenas o volume de acertos, mas também a natureza dos erros (como falsos positivos e falsos negativos), oferecendo uma visão clara sobre o desempenho do modelo em relação a cada classe da variável target.

6. CONSTRUÇÃO DO COMITÊ

A etapa final da modelagem consistiu na construção de um sistema de comitê, integrando os três classificadores desenvolvidos anteriormente: K-Nearest Neighbors (KNN), Árvore de Decisão e Support Vector Machine (SVM). O objetivo desta fase foi ir além da performance de um modelo isolado, criando uma estrutura capaz de combinar diferentes perspectivas matemáticas para gerar um diagnóstico final mais equilibrado e confiável.

6.1. Estratégia de Votação (Soft Voting)

Para a implementação do comitê, optou-se pela estratégia de Votação Ponderada (Soft Voting), executada através do algoritmo VotingClassifier. Esta escolha foi técnica e deliberada, distinguindo-se da votação majoritária simples (Hard Voting):

- **Funcionamento:** No Soft Voting, o comitê não considera apenas a decisão final de "doente" ou "saudável" de cada modelo. Em vez disso, o sistema soma as probabilidades atribuídas por cada um dos três classificadores a cada classe.
- **Vantagem:** Essa abordagem permite que modelos que possuem um alto grau de "confiança" em suas previsões tenham um peso maior na decisão final. Se um modelo está muito incerto sobre um caso específico, a probabilidade mais sólida dos outros modelos acaba por compensar essa incerteza, resultando em uma decisão colegiada que é, matematicamente, superior à soma das partes.

6.2. Justificativa da Robustez

A construção do comitê foi fundamental para reduzir o problema de viés individual. Enquanto o KNN foca na proximidade espacial, a Árvore de Decisão baseia-se em regras de corte e o SVM busca a maximização da margem de separação, cada modelo possui "pontos cegos" distintos.

Ao unir essas três lógicas sob uma mesma estrutura de votação, criamos um sistema de suporte à decisão que é mais resiliente. O resultado dessa integração é um modelo final menos suscetível a erros pontuais ou a ruídos nos dados de um único algoritmo, proporcionando uma ferramenta de diagnóstico mais estável para a triagem de pacientes em um cenário real.

7. RESULTADOS E MÉTRICAS

Nesta secção, são apresentados e discutidos os resultados obtidos pelos modelos implementados. A avaliação focou-se na capacidade de generalização dos algoritmos ao classificar os dados de teste, utilizando como métricas principais a Acurácia e a Matriz de Confusão.

7.1. Comparativo de Desempenho

A tabela abaixo resume o desempenho dos modelos individuais em comparação com o modelo de comitê:

Modelo	Acurácia (Exemplo)
K-Nearest Neighbors (KNN)	~0.796
Árvore de Decisão	~0.685
Support Vector Machine (SVM)	~0.870
Comitê (Voting Classifier - Soft)	0.8519

7.2. Análise da Matriz de Confusão (Modelo de Comitê)

A eficácia do modelo de comitê foi validada através da Matriz de Confusão, que detalha a distribuição dos acertos e erros do sistema:

Matriz de Confusão: $\begin{bmatrix} 29, 4 \\ 4, 17 \end{bmatrix}$

Interpretação:

- **Verdadeiros Negativos (29):** O modelo identificou corretamente 29 pacientes que não possuem doença cardíaca.
- **Verdadeiros Positivos (17):** O modelo identificou corretamente 17 pacientes que possuem doença cardíaca.
- **Falsos Positivos (4):** O modelo indicou a presença de doença em 4 pacientes saudáveis.
- **Falsos Negativos (4):** O modelo não identificou a doença em 4 pacientes que, na realidade, a possuem.

A acurácia global de **85,19%** demonstra um desempenho robusto do modelo de comitê. É importante notar que, em contextos médicos, o erro de **Falsos Negativos** (deixar passar um paciente doente) é o mais crítico. Com apenas 4 ocorrências, o modelo demonstra uma capacidade de triagem eficaz, embora reforce a necessidade de revisão humana em diagnósticos assistidos por inteligência artificial.

7.3. Conclusão sobre as Métricas

A utilização do Soft Voting permitiu que o sistema final não ficasse limitado ao desempenho do modelo mais fraco (Árvore de Decisão), alcançando um equilíbrio superior. Ao integrar as probabilidades de cada modelo, o comitê conseguiu suavizar as incertezas individuais, resultando numa ferramenta de suporte ao diagnóstico com maior estabilidade do que a utilização isolada de qualquer um dos algoritmos base.

8. DISCUSSÃO

Os resultados obtidos através da modelagem e do sistema de comitê oferecem percepções valiosas sobre a aplicação de técnicas de Machine Learning no diagnóstico clínico. A acurácia apresentada pelo modelo de comitê, comparada à oscilação de desempenho entre os algoritmos individuais, confirma a eficácia da estratégia de Ensemble na resolução de problemas complexos de classificação.

8.1. Análise da Robustez dos Modelos

A disparidade observada no desempenho dos modelos individuais (KNN, Árvore de Decisão e SVM) revela que cada algoritmo interpreta a "geometria" dos dados clínicos de formas distintas. Enquanto o SVM demonstrou alta capacidade em encontrar margens de separação ideais, o KNN mostrou-se sensível à densidade local das amostras. A construção do comitê foi, portanto, a decisão estratégica correta: ao combinar estas lógicas, o sistema conseguiu neutralizar os pontos cegos de cada algoritmo individual, resultando em um diagnóstico final mais resiliente e menos dependente de uma única abordagem estatística.

8.2. Limitações do Estudo

Embora os resultados sejam promissores, é fundamental reconhecer as limitações técnicas desta análise:

- **Tamanho do Dataset:** A base de dados utilizada (aproximadamente 300 registros) é limitada para padrões de Deep Learning ou sistemas de diagnóstico de alta complexidade. Embora suficiente para este projeto, a generalização do modelo em um ambiente hospitalar real exigiria um volume de dados significativamente maior e mais diversificado.
- **Qualidade e Viés:** Os dados clínicos estão sujeitos a variáveis que não foram capturadas aqui (fatores socioeconômicos, histórico genético detalhado, estilo de vida). O modelo aprendeu apenas com o que foi fornecido; portanto, deve ser interpretado como um auxiliar de decisão, não como uma verdade absoluta.

8.3. Implicações Clínicas

Este trabalho reforça o conceito de Inteligência Aumentada. O sistema não tem como objetivo substituir o médico, mas sim atuar como uma ferramenta de triagem eficiente. Ao identificar, com precisão de 85,19%, padrões sugestivos de doença cardíaca, a ferramenta pode

ajudar a otimizar o tempo das equipes de saúde, permitindo que casos de maior risco sejam priorizados na fila de atendimento.

A implementação demonstrou que a integração de múltiplos algoritmos pode transformar dados brutos em inteligência diagnóstica. A transição deste modelo de um ambiente de laboratório para uma aplicação real exigiria testes contínuos, validação clínica e, acima de tudo, a supervisão humana constante.

9. CONCLUSÃO

O projeto permitiu a implementação bem-sucedida de um sistema de inteligência artificial voltado para a classificação de doenças cardíacas, percorrendo todas as fases fundamentais da ciência de dados: desde o tratamento de dados brutos até à construção de um modelo preditivo robusto.

A aplicação prática dos algoritmos de K-Nearest Neighbors, Árvore de Decisão e Support Vector Machine revelou a importância de uma escolha técnica criteriosa. Contudo, a conclusão mais significativa deste trabalho reside na validação da estratégia de **Ensemble Learning**. Ao integrar os classificadores individuais num modelo de comitê (utilizando a técnica de Soft Voting), foi possível obter uma acurácia global de 85,19%, demonstrando que a colaboração entre diferentes lógicas estatísticas é superior à dependência de um modelo isolado.

Este exercício técnico evidenciou que a qualidade de um sistema de diagnóstico não depende apenas da complexidade dos algoritmos, mas sim da qualidade do pré-processamento dos dados e da arquitetura do comitê. A redução dos falsos negativos alcançada, embora exija cautela, aponta para um sistema de triagem com elevado potencial de aplicação prática em cenários reais de saúde, servindo como uma ferramenta de apoio à decisão clínica e não como um substituto da avaliação médica humana.

Em suma, o projeto cumpriu todos os objetivos propostos, demonstrando a viabilidade de aplicar métodos de aprendizagem automática para prever riscos cardíacos. Como perspectiva de futuro, este modelo poderá ser refinado com uma base de dados mais extensa, a incorporação de novas variáveis clínicas e a otimização de hiperparâmetros, visando elevar ainda mais a precisão e a fiabilidade do sistema para a prática clínica.